数据说明

一、数据来源

- **数据平台：** EVData 上海市新能源汽车（嘉定）数据创新实验室 · 数据开放平台
- **数据集页面：** https://labs.shevdc.com/datasets/view?dataSetCode=2100498347897913344
- **数据集名称：** EVData Box 教研数据集
- **发布机构：** 上海市新能源汽车（嘉定）数据创新实验室（依托上海市新能源汽车公共数据采集与监测研究中心平台数据资源）

二、五个数据集概况

#	数据集	英文名	时间跨度	正式版规模	格式	教学定位
①	国标32960入门数据集	EV_32960_BEGINNER_DATASET	1 个月（某年11月）	约 161 万行 / 26.26 MB	PARQUET（按车辆分区）	入门：国标认知与数据质量检测
②	新能源汽车多车辆运行数据集	EV_MORE_VEHICLE_DATASET	2 周（某年7月）	约 4,100 万行 / 760 MB	PARQUET（按日期分区）	进阶：群体行为与空间分析
③	新能源汽车长周期运行数据集	EV_LONG_PERIOD_DATASET	1 年	约 3,600 万行 / 580 MB	PARQUET（按车辆分区）	进阶：三电深度诊断与电池衰减
④	新能源汽车车型信息数据集	EV_VEHICLE_MODEL_DATASET	2019—2026	200 行（原始 100+修正 100）	Excel	入门：数据治理与车型研究
⑤	新能源汽车停留与充电行为数据集	EV_STAY_CHARGE_DATASET	1 个月（日期脱敏）	约 4.1 万条 / 约 7,300 辆车	Excel（4 张关联表）	综合：业务分析与商业决策建模

三、本地数据文件（DEMO 样例）实测口径

工作台内所有统计图表均基于本地 DEMO 数据文件用 Python（pandas / pyarrow / openpyxl）**实测计算**，口径如下：

数据集	本地文件	实测规模
① 国标32960入门	3 个 PARQUET 分区文件 + 车型 CSV	3 辆车 × 500 行 = **1,500 行**
② 多车辆运行	EV_MORE_VEHICLE_DATASET_demo.csv	**2,216 行**、3 辆车、2 个车型
③ 长周期运行	EV_LONG_PERIOD_DATASET_demo.csv	**2,095 行**、3 辆车（发动机数据占比 34.6%）
④ 车型信息	raw + correction 两个 xlsx	**100 + 100 行（全量）**
⑤ 停留与充电	trip_stay_charge_data（DEMO）等 4 个 xlsx	**500 条停留事件**、164 辆车、66 个车型、101 条含充电（20.2%）

四、关键数据口径与避坑要点

1. **GB/T 32960 异常码约定：** 254(0xFE)=异常、255(0xFF)=无效（双字节为 65534/65535，四字节里程为 4294967294/4294967295），统计前须过滤或置 NULL；
2. **嵌套结构：** origin_data 的 vehicledata / vehicleposition / enginedata / extremevalue 为 struct，motordatalist 为 struct 套 array（需 explode 展开）；
3. **非唯一时间键：** (evdata_vehicle_id, date, time) 不唯一，DEMO 实测 1,500 行中有 250 条同车同时刻重复记录，差分计算前须处理；
4. **坐标系与无效坐标：** 经纬度为 WGS84 坐标系，(0,0) 坐标不可用，空间分析前须过滤无效定位；
5. **电流方向：** 总电流负值放电、正值充电；
6. **停留充电数据集：** 日期经偏移脱敏且非整周平移，时间与 week_n、day_type 不对应，时间维度分析应优先使用 week_n 与 day_type；停留不足 10 分钟且未充电的记录已被过滤；cdz_id / uid 为空本身携带业务信息（非充电站区域 / 非 AOI 归属地），不可删行；
7. **车型信息数据集：** 原始表存在单位混用与品牌异体，面向发布的分析须使用修正表；厂商指导价 ≠ 终端成交价。

五、数据合规说明

车辆 ID、车型代码已由数据提供方脱敏（随机编码，不可逆推）；日期已偏移处理；数据集不包含手机号、身份证号、车牌号等个人敏感信息（PII）。本作品仅用于 X-GAME 2026 天华学院校内赛教学竞赛场景，不对外分发数据。空间分析保持在群体/区域聚合层面，不输出单车可识别轨迹明细。